

# 第七章-目标识别

---

## 第七章-目标识别

### 7.1 基础知识

### 7.2 模式和模式分类

### 7.3 基于决策理论方法的识别

#### 7.3.1 最小距离分类器

#### 7.3.2 相关匹配

#### 7.3.3 最佳统计分类器

##### 7.3.3.1 贝叶斯分类器

##### 7.3.3.2 高斯模式类的贝叶斯分类器

## 7.1 基础知识

---

目标识别的任务是检测出图片中感兴趣的物体，并对其进行分类

输入：图片

输出：框住的物体+分类的置信度

## 7.2 模式和模式分类

---

- 模式（pattern）：一堆描述子的集合
- 特征：描述子
- 模式类：一堆有共同属性的模式
- 模式向量：每个分量表示一个描述子

## 7.3 基于决策理论方法的识别

---

用 $\mathbf{x}=(x_1, x_2, \dots, x_n)^T$ 表示一个n维模式向量，对于有 W 个模式的模式类 $w_1, w_2, \dots, w_W$ 决策理论模式识别的基本问题是根据如下属性来找到W个决策函数 $d_1(x), d_2(x), \dots, d_W(x)$ ,如果 $\mathbf{x}$ 属于类 $w_i$ 则

$$d_i(x) > d_j(x) \quad j = 1, 2, 3, \dots, W; j \neq i \quad (1)$$

即将 $\mathbf{x}$ 带入决策函数后， $d_i(x)$ 得到最大值，则称模式 $\mathbf{x}$ 属于第i个模式类

**决策边界**

$$d_j(x) - d_i(x) = 0 \quad (2)$$

或

$$d_{ij}(x) = d_i(x) - d_j(x) = 0 \quad (3)$$

对于模式i,  $d_{ij} > 0$ , 对于模式j,  $d_{ij} < 0$

## 7.3.1 最小距离分类器

将每个模式定义为该类模式的平均向量

$$m_j = \frac{1}{N_j} \sum_{x \in \omega_j} x_j \quad j = 1, 2, \dots, W \quad (4)$$

欧氏距离定义如下

$$D_j(x) = \|x - m_j\| \quad j = 1, 2, \dots, W \quad (5)$$

其中 $\|a\| = (a^T a)^{1/2}$ 是欧几里得范数

若 $D_j$ 是最小距离，就把 $x$ 赋给 $w_j$ ，也即等同于计算如下函数的最大值

$$d_j(x) = x^T m_j - \frac{1}{2} m_j^T m_j \quad j = 1, 2, \dots, W \quad (6)$$

当 $d_j(x)$ 获得最大值的时候，就将 $x$ 赋给 $w_j$

**决策边界**

$$d_{ij} = d_i(x) - d_j(x) = x^T (m_i - m_j) - \frac{1}{2} (m_i - m_j)^T (m_i + m_j) = 0 \quad (7)$$

**举例说明**

- The two classes , Iris versicolor and Iris setosa , denoted  $\omega_1$  and  $\omega_2$  respectively, have sample mean vectors  $m_1 = (4.3, 1.3)^T$  and  $m_2 = (1.5, 0.3)^T$  ,the decision functions are

$$\begin{aligned} d_1(x) &= x^T m_1 - \frac{1}{2} m_1^T m_1 \\ &= 4.3x_1 + 1.3x_2 - 10.1 \end{aligned}$$

and

$$\begin{aligned} d_2(x) &= x^T m_2 - \frac{1}{2} m_2^T m_2 \\ &= 1.5x_1 + 0.3x_2 - 1.17 \end{aligned}$$

## 7.3.2 相关匹配

$$\gamma(x, y) = \frac{\sum_s \sum_t [w(s, t) - \bar{w}] [f(x + s, y + t) - \bar{f}_{xy}]}{\left\{ \sum_s \sum_t [w(s, t) - \bar{w}]^2 \sum_s \sum_t [f(x + s, y + t) - \bar{f}_{xy}]^2 \right\}^{\frac{1}{2}}}$$

## 7.3.3 最佳统计分类器

### 7.3.3.1 贝叶斯分类器

- 判定一个模式 $\mathbf{x}$ 为模式 $w_i$ 的概率记为 $P(w_i | \mathbf{x})$
- 模式类 $w_i$ 的先验概率为 $P(w_i)$
- 记将模式 $\mathbf{x}$ 判断为 $w_j$ ，但实际来自 $w_i$ 的损失为 $L_{ij}$

综上所述，当我们把一个模式 $\mathbf{x}$ 判断归为 $w_j$ 类时，其平均损失为

$$r_j(\mathbf{x}) = \sum_{k=1}^W L_{kj} p(w_k | \mathbf{x}) \quad (8)$$

根据全概率公式 $p(A/B) = [p(B/A)p(A)]/p(B)$

$$r_j(\mathbf{x}) = \frac{1}{p(\mathbf{x})} \sum_{k=1}^W L_{kj} p(\mathbf{x} | w_k) p(w_k) \quad (9)$$

🏠 这样替换是因为我们已知先验概率 $p(w_i)$

由于 $\frac{1}{p(\mathbf{x})}$ 为正，且对所有 $w_i$ 都一样，所以可以忽略它，因此平均损失简化为

$$r_j(\mathbf{x}) = \sum_{k=1}^W L_{kj} p(\mathbf{x} | w_k) p(w_k) \quad (10)$$

对于每一个 $x$ ，计算所有 $r_j(x)$ ,  $j = 1, 2, \dots, W$ 将 $x$ 赋给使损失最小的那个模式类

这种将总体损失降至最低的分类器我们成为贝叶斯分类器

### 7.3.3.2 高斯模式类的贝叶斯分类器

如果一个类的概率密度是高斯分布的，那么其决策函数为

$$d_j(x) = p(x|w_j)P(w_j) = \frac{1}{\sqrt{(2\pi)\sigma_j}} e^{-\frac{(x-m_j)^2}{2\sigma_j^2}} P(w_j) \quad (11)$$

n维情况下

$$p(x|w_j) = \frac{1}{(2\pi)^{n/2} |C_j|^{1/2}} e^{-\frac{1}{2}(x-m_j)^T C_j^{-1} (x-m_j)} \quad (12)$$


其中

$$m_j = E_j\{x\} = \frac{1}{N_j} \sum_{x \in w_j} x \quad (13)$$

$$C_j = E_j\{(x - m_j)(x - m_j)^T\} = \frac{1}{N_j} \sum_{x \in w_j} xx^T - m_j m_j^T \quad (14)$$

**举例**

给定一个3个特征的特征空间，上面的点及其分类如下，请计算决策边界



$$w_1 \quad (0,0,0) \quad (1,0,1) \quad (1,0,0) \quad (1,1,0)$$

$$w_2 \quad (0,0,1) \quad (0,1,1) \quad (0,1,0) \quad (1,1,1)$$

$$m_1 = \frac{1}{4} \begin{pmatrix} 3 \\ 1 \\ 1 \end{pmatrix} \quad m_2 = \frac{1}{4} \begin{pmatrix} 1 \\ 3 \\ 3 \end{pmatrix}$$

$$C_1 = \frac{1}{4} \sum x x^T - m_1 m_1^T = \frac{1}{4} \left[ \begin{pmatrix} 3 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix} - 4 \frac{1}{4} \begin{pmatrix} 3 \\ 1 \\ 1 \end{pmatrix} \frac{1}{4} (3 \ 1 \ 1) \right] = \frac{1}{16} \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{pmatrix}$$

$$\begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} (0 \ 0 \ 0) = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} (1 \ 0 \ 1) = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} (1 \ 0 \ 0) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} (1 \ 1 \ 0) = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \quad 4 \text{个加起来为} \begin{pmatrix} 3 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

$$\text{同理得 } C_2 = \frac{1}{16} \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{pmatrix}$$

$$d_j(x) = x^T C^{-1} m_j - \frac{1}{2} m_j^T C^{-1} m_j$$

$$\text{求出 } d_1(x) = 4x_1 - 1.5 \quad d_2(x) = -4x_1 + 8x_2 + 8x_3 - 5.5$$

$$\text{令 } d_1(x) = d_2(x) \text{ 得}$$

$$8x_1 - 8x_2 - 8x_3 + 4 = 0 \quad \text{决策面}$$